تمرین ششم

تینا صداقت ۹۳۳۱۰۴۴

درهر بلوک از روش درخت استفاده می‌شود. باید بتوانیم چندین بلوک از نخها داشته باشیم تا بتوان آرایه‌های بزرگ را پردازش کرد و همه‌ی پردازنده‌های GPU را مشغول نگه داشت و هر بلوک یک قسمت از پردازش آرایه را انجام دهد. حال اینکه چطور این نتیجه‌های جزئی را حساب کنیم. اگر بتوانیم همه‌ی بلوکهای نخها را سنکرون کنیم: باید یک global sync بعد از تولید نتیجه هر بلوک داشته باشیم و هر وقت همه‌ی بلوکها به آن sync رسیدند به طور بازگشتی ادامه دهیم. اما کودا یک global synchronization ندارد به دلیل اینکه هزینه ساخت آن در سخت افزار زیاد است و برنامه نویس را مجبور می‌کند که تعداد کم تری بلوک داشته باشد تا از deadlock جلوگیری کند.

راه حل: به چندین کرنل تجزیه کنیم:

- که در آن اجرا شدن تابع کرنل خودش یک نقطه‌ی همگام سازی است.
- Overhead سخت‌افزار و نرم‌افزار قابل چشم پوشی است.

تجزیه به چندین کرنل باعث جلوگیری از global sync می‌شود. در خصوص reduction ها کد برای همه‌ی مراحل یکسان است.(فراخوانی کرنل بازگشتی)

هدف بهینه سازی:

- باید تلاش کنیم تا به ماکسیمم کارایی GPU برسیم.
- از متریک درست استفاده کنیم:
  - GFLOP/s: برای کرنل‌های محاسباتی
  - Bandwidth: برای کرنل‌های حافظه‌ای
- Reduction ها شدت محاسباتی خیلی کمی دارند.
  - یک flop برای لود کردن یک المان(پهنای باند بهینه)
- بنابراین باید برای پهنای باند زیاد تلاش کنیم.
- برای این تمرین از GeForce GT 750M استفاده شده است.
  - 384-bit memory interface و 900MHz DDR3

$$957 * 10^6 * (384/8) * 2 / 10^9 = 91 \text{ GB/s}$$

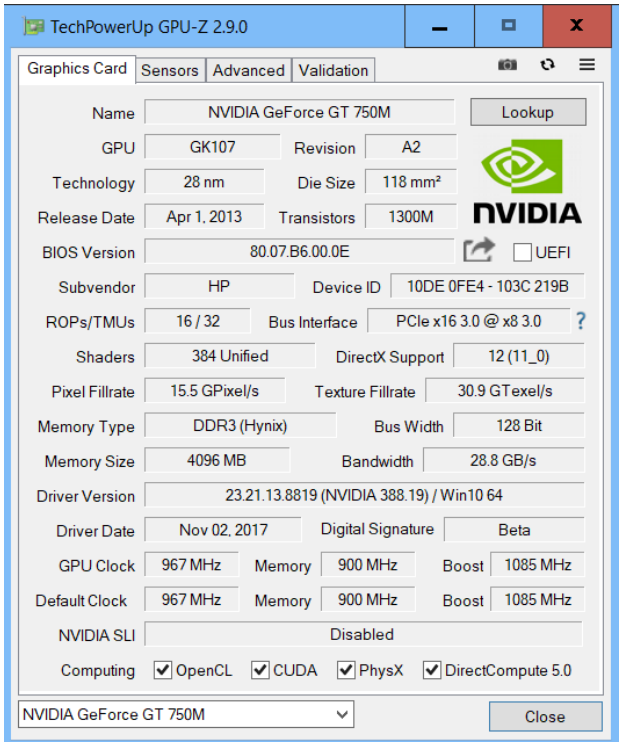

ابتدا کد سریال را چندین بار اجرا کردم و میانگین زمان سریال را از روی نتایج به دست آمده حساب کردم:

5004 , 3006 , 2704,7258,2767,5466 => 4367

Reduction#1: آدرس‌دهی برگ برگ شده:

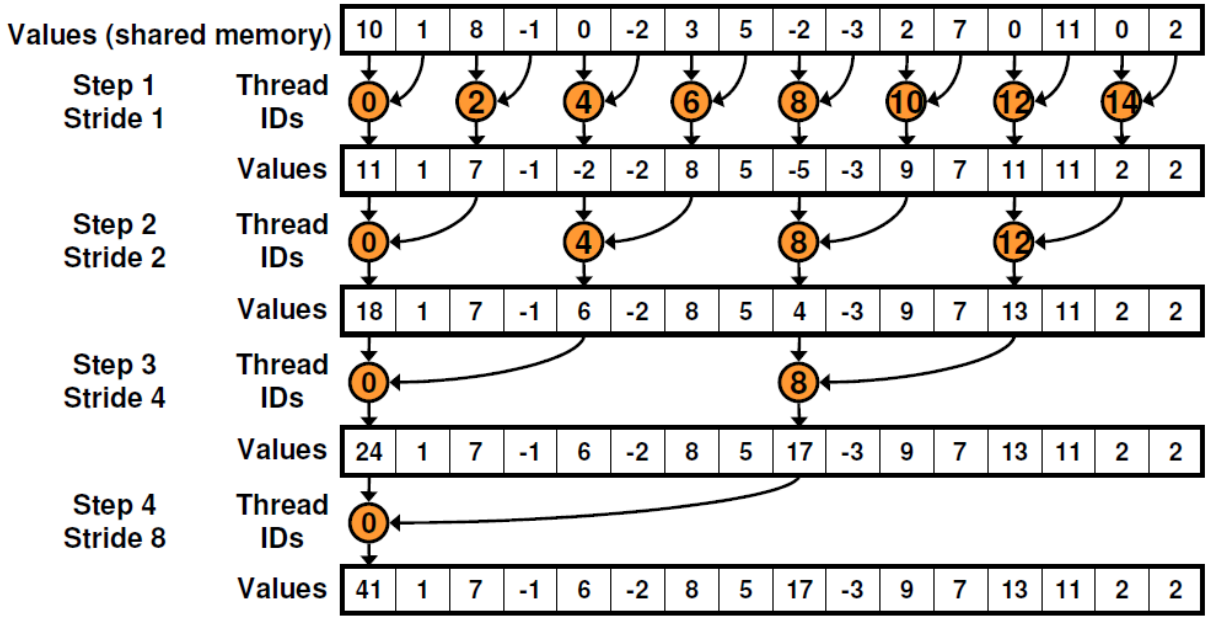

در این الگوریتم هر نخ یک المان از آرایه‌ی global را در آرایه‌ی shared کپی می‌کند. در مرحله اول نخ‌هایی با اندیس‌های زوج دوتا دوتا عمل جمع را انجام می‌دهند و در خانه با اندیس کمتر قرار می‌دهند. در مرحله دوم همین کار با نخ‌های با مضرب ۴ انجام می‌شود. در مرحله بعد ضریب ۸ ...

نتیجه‌ی محاسبات هر بلوک در g_outData[blockIdx.x] ذخیره می‌شود. بسته به تعداد بلوک‌هایی که داریم باید تعیین کنیم که چند بار تابع کرنل لانچ شود.

```
__global__ void reduce0(int *g_inData, int *g_outData)
{
	extern __shared__ int sdata[];

	// each thread loads one element from global to shared mem
	unsigned int tid = threadIdx.x;
	unsigned int i = blockIdx.x * blockDim.x + threadIdx.x;
	sdata[tid] = g_inData[i];
	__syncthreads();

	// do reduction in shared mem
	for (unsigned int s = 1; s < blockDim.x; s *= 2) {
		if (tid % (2 * s) == 0) {
			sdata[tid] += sdata[tid + s];
		}
		__syncthreads();
	}

	// Write the result for this block to global mem
	if (tid == 0) {
		g_outData[blockIdx.x] = sdata[0];
	}
}
```

مشکل: branch های مختلف زیاد که کارایی را پایین می‌آورد.

یک تابع int reduction(int *a) با ورودی پوینتر به شروع آرایه a داریم. در این آرایه اول پوینتر های ورودی و خروجی را تعریف می‌کنیم و برای آنها در device حافظه در نظر می‌گیریم. سایز آرایه‌ها باید به اندازه N باشد یعنی: int memSize = N * sizeof(int);

اندازه گرید و سایز بلوک ها:

```
int grid_x = N / BLOCK_SIZE;
int block_x = BLOCK_SIZE;
```

اینها را به این شکل می‌نویسیم تا بعدا در تابع کرنل بیایند.

```
dim3 gridDimensions(grid_x, 1, 1);
dim3 blockDimensions(block_x, 1, 1);
```

تایمر های Start و stop را تعریف می‌کنیم. و تایمر شروع را اجرا می‌کنیم.

تابع کرنل به صورت زیر تعریف می‌شود که ابعاد گرید و بلوک و اختصاص حافظه ی بلوک در تعریف آن می‌آیند و همچنین ورودی d_A و خروجی d_Blocks است.

```
// Execute Kernels
reduce0 << <gridDimensions, blockDimensions, block_x*sizeof(int) >> > (d_A, d_Blocks);
```

اما اگر تعداد بلوک ها زیاد باشد باید این تابع کرنل چند بار صدا زده شود با این تفاوت که در دفعه های بعد ورودی d_Blocks می‌شود. (reduction)

تایمر خروجی را فرا میخوانیم و زمان سپری شده را نمایش می‌دهیم. خروجی تولید شده از کرنل‌ها را در آرایه a در host کپی می‌کنیم و نشان می‌دهیم.

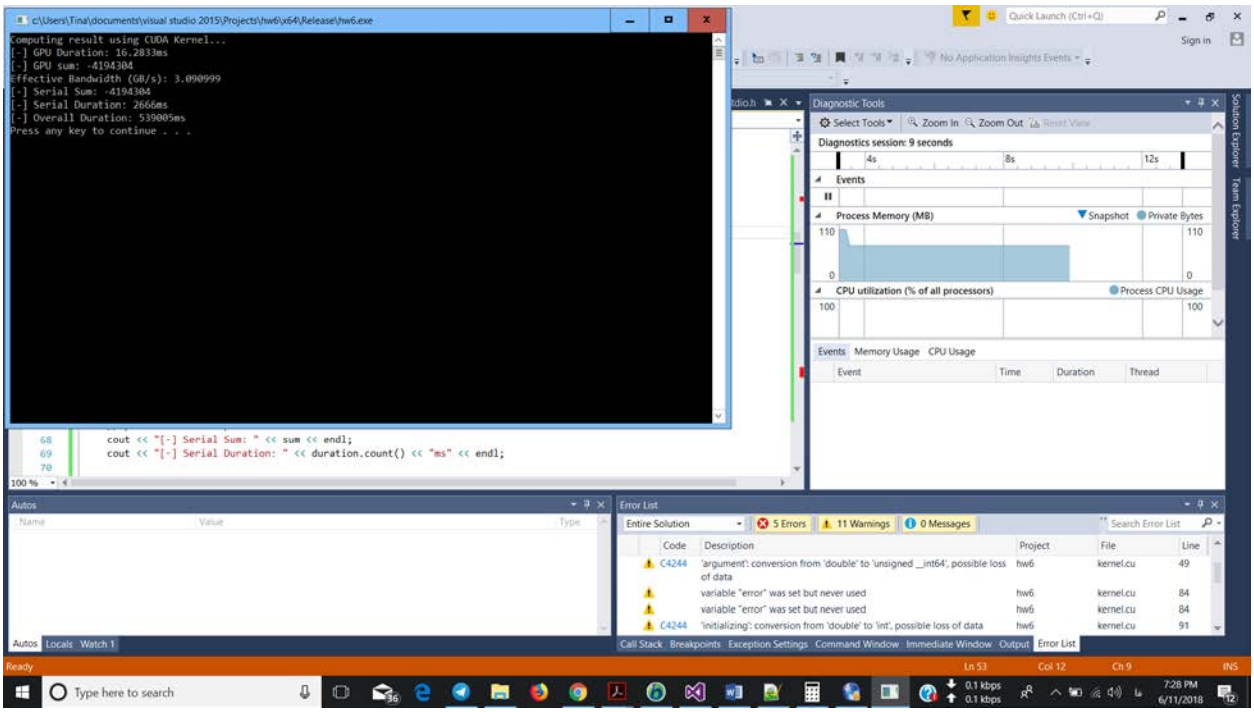

Reduction#2: آدرس‌دهی برگ برگ شده:

کد مثل قبل است با این تفاوت که در قسمتی که reduction در shared memory انجام می‌شود این کد را می‌نویسیم:

```
for (unsigned int s = 1; s < blockDim.x; s *= 2) {
	int index = 2 * s * tid;
	if (index < blockDim.x) {
		sdata[index] += sdata[index + s];
	}
	__syncthreads();
}
```

به جای branchهای مختلف، index را به فرم `int index = 2 * s * tid;` تعریف می‌کنیم.

مشکل جدیدی به وجود می‌آید که همان shared memory bank conflict است.

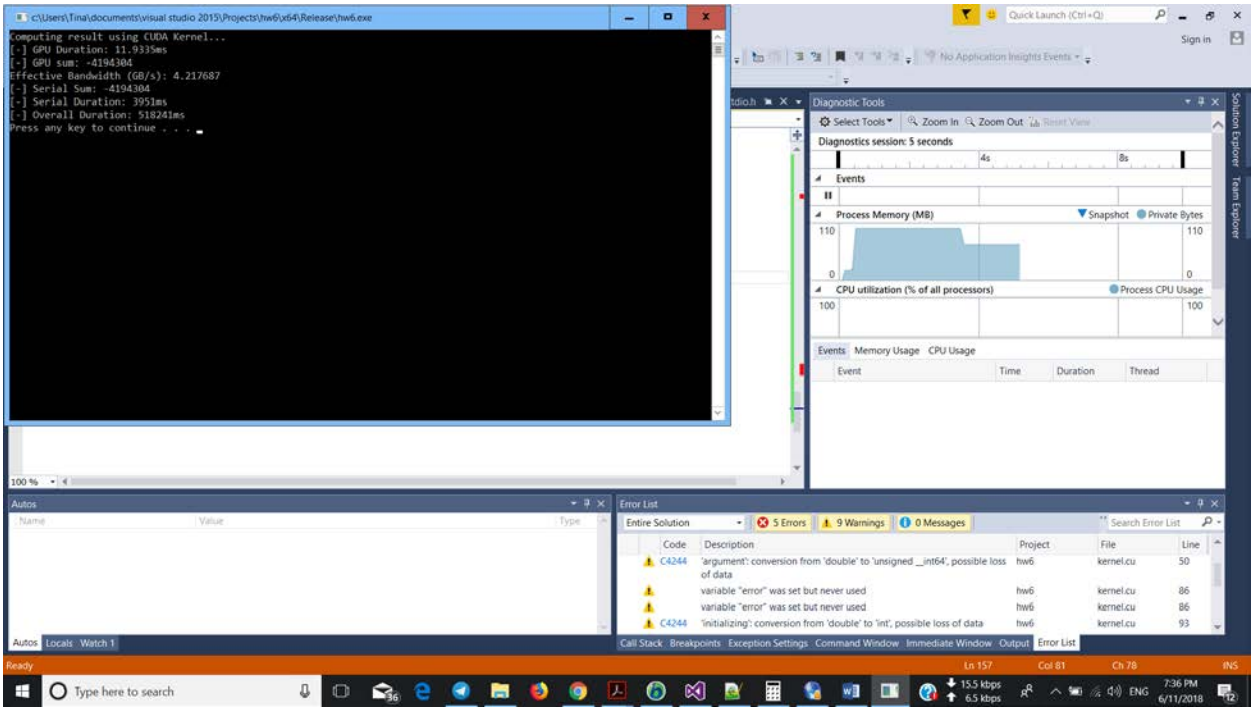

Reduction#3: آدرس‌دهی سریالی:

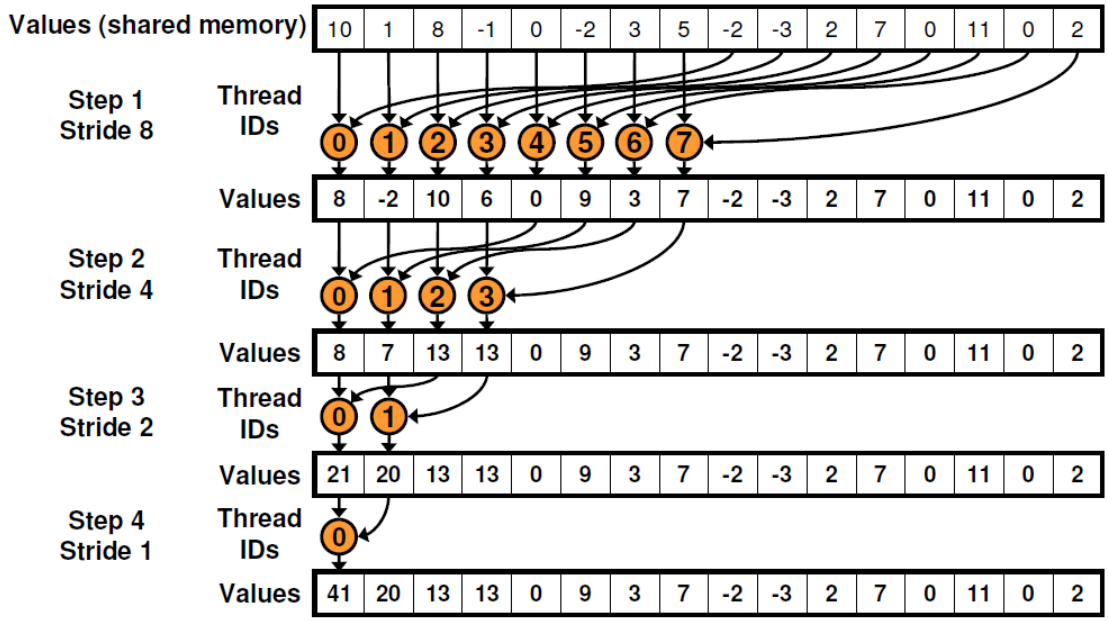

Sequential addressing is conflict free


```
__g
{
```

```
// Fill up the shared memory
```

```
        sdata[tid] = g_inData[i];

        // Fixed bank conflicts with sequential addressing
        __syncthreads();
        for (unsigned int s = blockDim.x / 2; s > 0; s >>= 1) {
                if (tid < s)
                        sdata[tid] += sdata[tid + s];

                __syncthreads();
        }

        // Write the result for this block to global memory
        if (tid == 0) {
                g_outData[blockIdx.x] = sdata[0];
        }

}
```

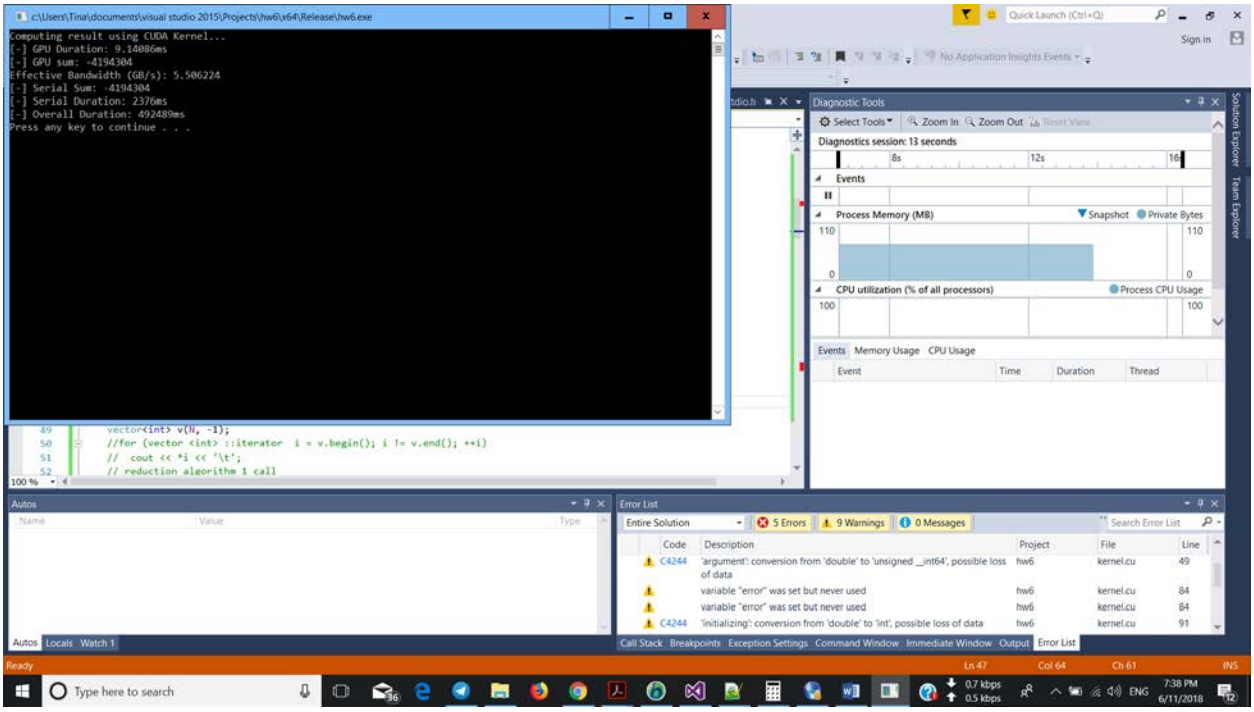

نخ های بیکار:

```
for (unsigned int s=blockDim.x/2; s>0; s>>=1) {
if (tid < s) {
sdata[tid] += sdata[tid + s];
}
__syncthreads();
}
```

در تکرار حلقه اول نصف نخ ها بیکار هستند!

Reduction#4: جمع اول هنگام لود:

تعداد بلوک ها را نصف می‌کنیم (۶۴) و یک load تکی می‌گذاریم. یعنی به جای:

```
unsigned int tid = threadIdx.x;
unsigned int i = blockIdx.x * blockDim.x + threadIdx.x;
sdata[tid] = g_inData[i];
__syncthreads();
```

کد زیر را می‌نویسیم:

```
// perform first level of reduction,
// reading from global memory, writing to shared memory
unsigned int tid = threadIdx.x;
unsigned int i = blockIdx.x*(blockDim.x * 2) + threadIdx.x;

// Fill up the shared memory
sdata[tid] = g_inData[i] + g_inData[i + blockDim.x];
__syncthreads();
```

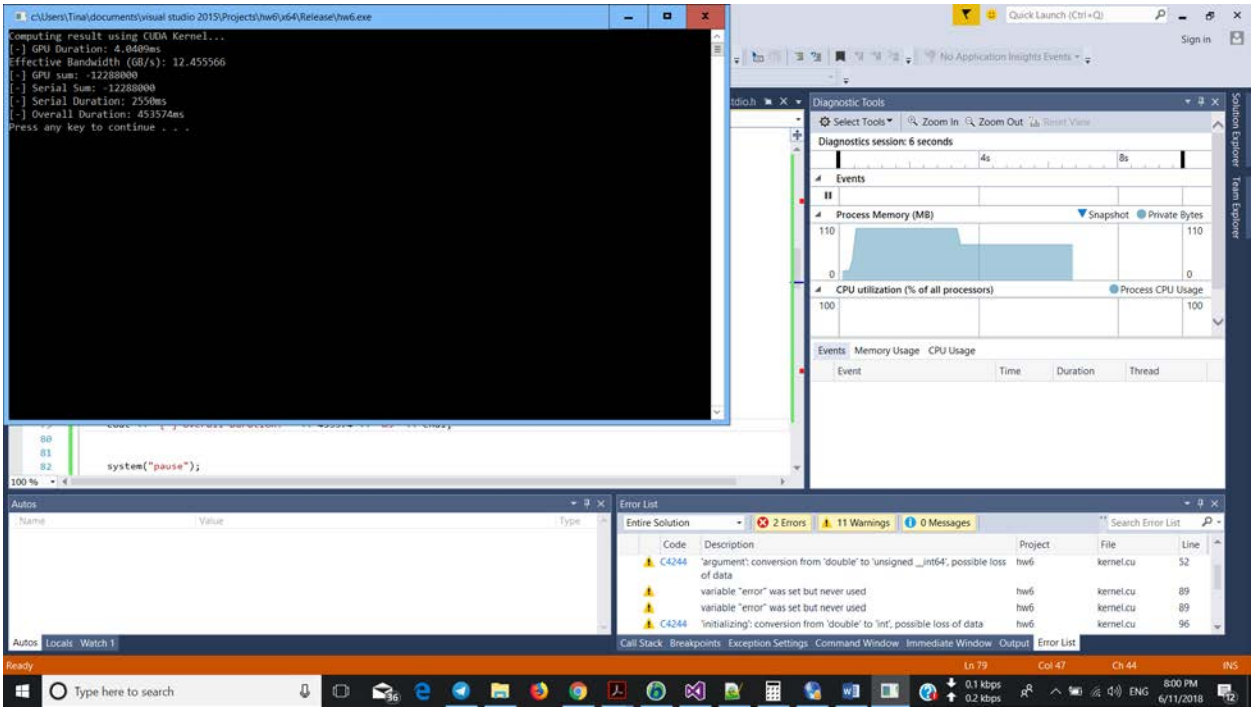

Reduction#5: آخرین warp را از حلقه بیرون می‌آوریم:

گلوگاه دستورها:

در 17GB/s ما خیلی دور از محدوده ی پهنای باند هستیم و می‌دانیم که Reduction شدت محاسباتی کمی دارد. پس احتمالا یک گلوگاه سربار دستور وجود دارد. دستورات فرعی (غیر از load و store و محاسبات هسته) یعنی محاسبات آدرس‌ها و سربار حلقه

راه حل: حلقه را باز کنیم.

آخرین warp را باز کنیم:

همینطور که Reduction جلو می‌رود، تعداد نخ های فعال کم می‌شود. وقتی s<=32 شود، فقط یک warp باقی می‌ماند. دستورات در warp، single instrudtion multiple data هستند. یعنی وقتی s<=32 باشد لزومی به استفاده از synchthread() ___ نداریم. به بخش if(tid<s) هم نیازی نداریم چون هیچ کاری را سیو نمی‌کند. پس ۶ تا تکرار آخر را از حلقه بیرون می‌آوریم.

```
for (unsigned int s = blockDim.x / 2; s>32; s >>= 1)
{
	if (tid < s)
		sdata[tid] += sdata[tid + s];
```

```
        __syncthreads();
}
if (tid < 32)
{
        sdata[tid] += sdata[tid + 32];
        sdata[tid] += sdata[tid + 16];
        sdata[tid] += sdata[tid + 8];
        sdata[tid] += sdata[tid + 4];
        sdata[tid] += sdata[tid + 2];
        sdata[tid] += sdata[tid + 1];
}
```

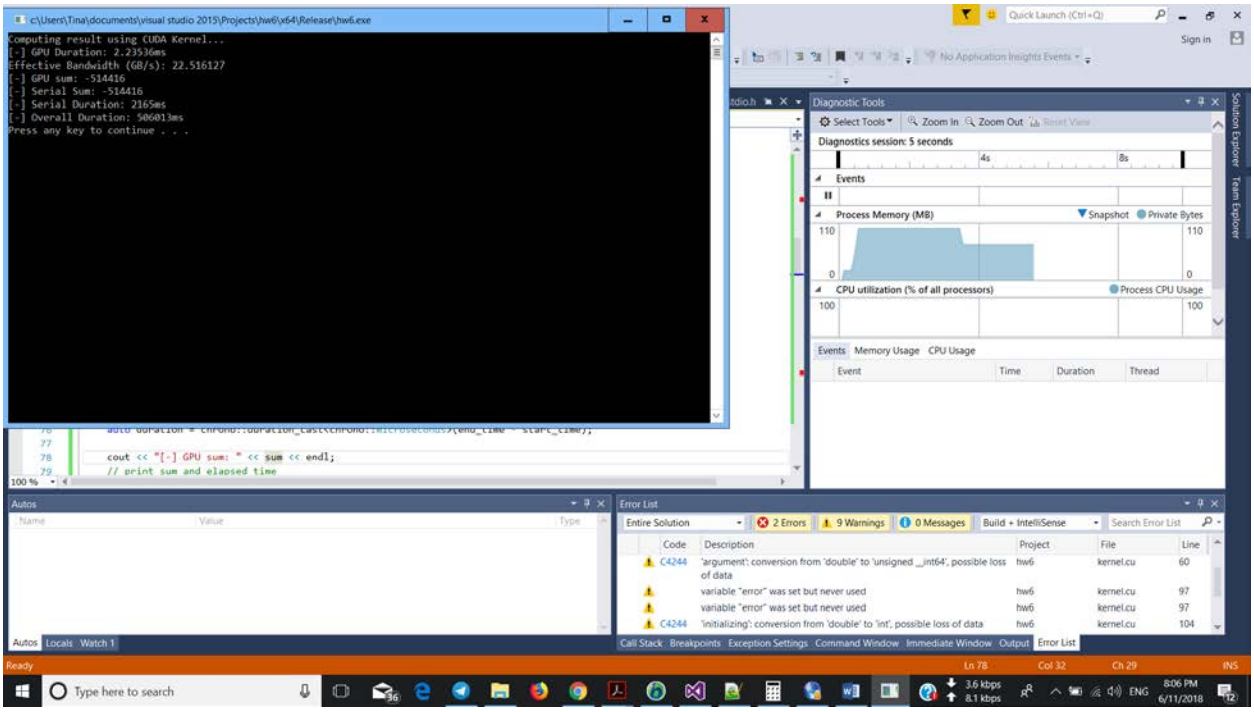

محاسبه bandwidth:

Bandwidth تئوری: (peak bandwidth)

Memory clock rate: 957 MHz

Memory interface: 384 bit

$BW_{theoretical}$ = 957 * 10^6 * (384/8) * 2 / 10^9 = 91 GB/s

تقسیم بر ۸ برای اینکه بیت را به بایت تبدیل کنیم. دو سرعت داده دو برابر است ضربدر دو هم می‌شود. برای رسیدن به GB/s باید تقسیم بر 10^9 کنیم.

Bandwidth موثر:

$$BW_{Effective} = (R_B + W_B) / (t * 10^9)$$

R_B تعداد بایت های خوانده شده از کرنل، و W_B تعداد بایتهای نوشته شده در کرنل و t زمان سپری شده بر حسب ثانیه است.

کد محاسبه bandwidth:

```
printf("Effective Bandwidth (GB/s): %f \n", N * 4 * 3 / elapsed_time / 1e6);
```

N*4 تعداد بایت های خوانده شده یا نوشته شده از هر آرایه است. ۳ هم نمایش دهنده خواندن d_A و خواندن و نوشتن d_Blocks است.

نتایج:

با توجه به pdf داده شده، من هم سایز بلوک ها را ۱۲۸ گرفتم.

	زمان محاسبات	زمان کل (محاسبات + انتقال داده‌ها)	bandwidth	speedup
Kernel1 Interleaved addressing with divergent branching	16.2833	539005	3.09	4367/16.28=272.93
Kernel2 interleaved addressing with bank conflicts	11.9335	518241	4.21	4367/11.933=365.9
Kernel 3 sequential addressing	9.14086	492489	5.50	4367/9.14=477
Kernel4 first add during global load	4.0409	45327	12.45	4367/4.04=1072
Kernel5 unroll last warp	2.3553	43741	22.51	4367/2.33= 1858